

# L'ingegneria del dato

---

L'ingegneria del dato è l'arte di portare i dati "grezzi" a diventare dati "utilizzabili" in modo corretto, efficiente e ripetibile.

Non analizza i dati (quello viene dopo), li prepara bene.

---

## 1 Ruolo dell'ingegneria del dato nel corso

Nel tuo corso l'ingegneria del dato:

parte dal database

usa Python come strumento operativo

prepara i dati per analisi, report e applicazioni

Schema mentale semplice per gli studenti:

Sorgenti dati → Database → Python → Dati puliti e pronti

---

## 2 Fondamenti database (base dell'ingegneria del dato)

Concetti chiave da collegare all'ingegneria del dato

Tabelle, record, attributi

Chiavi primarie e chiavi esterne

Integrità referenziale

Tipi di dato

Normalizzazione (almeno 1NF–3NF)

Query SQL (SELECT, JOIN, GROUP BY)

Messaggio didattico importante

Un Data Engineer ragiona prima in termini di modello dati, poi scrive codice.

Esempio concettuale:

"Posso importare questi dati?"

"Sono coerenti?"

"Posso collegarli ad altre tabelle?"

---

## 3 Python come strumento di ingegneria del dato

Python non sostituisce il database, lo potenzia.

Usi principali nel corso

Lettura dati da file (CSV, JSON)

Connessione al DB

Trasformazione dei dati

Controllo qualità

Automazione

---

## **4** Pipeline semplificata (ETL didattica)

Introdurre ETL in modo leggero e concreto:

E – Extract (estrazione)

File CSV

File JSON

Database

`import csv`

oppure

`import json`

---

T – Transform (trasformazione)

Pulizia dati

Conversione tipi

Controlli di coerenza

Arricchimento

Esempi didattici:

Date come stringhe → date reali

Campi vuoti → NULL

Codici duplicati → errore

`if eta < 0: raise ValueError("Età non valida")`

---

## L – Load (caricamento)

Inserimento nel database

Uso di transazioni

Rollback in caso di errore

INSERT INTO studenti (...)

Messaggio chiave:

Il database deve restare consistente, anche se il file di origine è sporco.

---

## 5 Qualità del dato (tema fondamentale)

Qui l'ingegneria del dato diventa "seria".

Concetti da introdurre

Dati mancanti

Dati duplicati

Dati incoerenti

Vincoli violati

Esempio didattico:

Uno studente senza matricola

Un voto fuori range

Un esame senza studente

---

## 6 Ingegneria del dato ≠ Analisi dei dati

Chiarire bene la differenza:

Ingegneria del dato   Analisi dei dati

Prepara i dati   Studia i dati   Controlla qualità   Fa statistiche   Usa DB + Python   Usa grafici, ML

Frase da ricordare agli studenti:

"Se i dati sono sbagliati, l'analisi sarà sbagliata, anche se il codice è perfetto."

---

## 7 Esempio didattico completo (mini-caso)

Scenario

File studenti.csv

Database scuola

Obiettivi

Importare studenti

Validare dati

Inserire solo quelli corretti

Competenze coinvolte

File system

Python

SQL

Transazioni

Controlli

Questo è ingegneria del dato, anche senza Big Data.

---

## 8 Obiettivo formativo del corso

Alla fine del corso lo studente deve saper:

leggere dati da fonti diverse

capire se i dati sono affidabili

progettare tabelle corrette

usare Python per automatizzare

caricare dati senza "rompere" il database

---

## 9 Messaggio finale per gli studenti

Prima di fare grafici, intelligenza artificiale o machine learning bisogna saper costruire dati buoni.